

**Zadanie nr 4 – Modyfikacja algorytmu
SABOA
zwiększająca różnorodność roju
(DESABOA)**

Techniki Inteligentnej Analizy Danych

Nikodem Nowak, 251598 Bartosz Kołaciński, 251554

2026-05-24

Spis treści

1	Cel zadania	1
2	Wstęp teoretyczny	1
2.1	Algorytm BOA	1
2.2	Algorytm SABOA	1
2.3	Proponowana modyfikacja DESABOA	2
3	Eksperymenty i wyniki	3
3.1	Konfiguracja badań	3
3.2	Wyniki liczbowe	3
3.3	Krzywe zbieżności	4
3.4	Rozkłady błędu końcowego	5
3.5	Test skuteczności (Wilcoxon)	6
4	Wnioski	7

1 Cel zadania

Celem zadania było zaproponowanie modyfikacji jednego z rojowych algorytmów optymalizacji – GGL-PSOD lub SABOA – zwiększającej różnorodność roju i poprawiającej skuteczność metody, a następnie eksperymentalne potwierdzenie jej wyższości nad algorytmem bazowym. Do modyfikacji wybrano algorytm **SABOA** [3], zbudowany na algorytmie **BOA** [1]. Zaproponowany wariant, nazwany **DESABOA** (*Diversity-Enhanced SABOA*), wprowadza dwa mechanizmy przeciwdziałające przedwczesnej zbieżności roju. Zakres prac obejmował:

- implementację algorytmu bazowego SABOA oraz proponowanego DESABOA;
- dobór parametrów: zakres poszukiwań, wymiar D , budżet ewaluacji funkcji celu;
- badania na 12 funkcjach z zestawu **CEC2017** [2] obejmujących wszystkie cztery kategorie (unimodalne, multimodalne, hybrydowe, złożone);
- uśrednienie wyników po **51 niezależnych przebiegach** każdej funkcji;
- porównanie z SABOA oraz weryfikację istotności statystycznej testem sumy rang **Wilcoxa**.

2 Wstęp teoretyczny

2.1 Algorytm BOA

W algorytmie BOA [1] każdy motyl wytwarza zapach o natężeniu $f = cI^a$, gdzie I to natężenie bodźca (jakość rozwiązania), c – modalność sensoryczna, a – wykładnik. Z prawdopodobieństwem przełączania p motyl wykonuje ruch globalny ku najlepszemu osobnikowi g^* albo ruch lokalny względem dwóch losowych osobników x_j, x_k :

$$\text{globalny: } x_i \leftarrow x_i + (r_1 r_2 g^* - x_i) f_i, \quad (1)$$

$$\text{lokalny: } x_i \leftarrow x_i + (r_1 r_2 x_j - x_k) f_i, \quad (2)$$

gdzie $r_1, r_2 \sim U(0, 1)$.

2.2 Algorytm SABOA

SABOA [3] upraszcza BOA, usuwając parametry c , a oraz natężenie I ; jedynym parametrem pozostaje p . Współczynnik zapachu jest samoadaptacyjny i maleje liniowo w czasie, $f = u(1 - t/T)$, $u \sim U(0, 1)$, gdzie t – numer iteracji, T – liczba iteracji. Aktualizacja położenia (zgodnie z publiczną implementacją referencyjną, gdyż artykuł źródłowy jest płatny):

$$\text{globalny: } x_i \leftarrow x_i + g^* + (x_i - g^*) f, \quad (3)$$

$$\text{lokalny: } x_i \leftarrow 0,5(g^* + w^*) f, \quad (4)$$

gdzie w^* to najgorszy osobnik. Mały współczynnik $f \in (0, 1)$ daje krótkie kroki, przez co rój szybko traci różnorodność i przedwcześnie zbiega – ta słabość jest celem modyfikacji.

2.3 Proponowana modyfikacja DESABOA

DESABOA rozszerza SABOA o dwa mechanizmy zwiększające różnorodność roju.

(a) Uczenie przez przeciwności (OBL). Obok losowej populacji $P = \{x_i\}$ generowana jest populacja przeciwna $\check{x}_{i,j} = lb_j + ub_j - x_{i,j}$; oceniane jest $2N$ punktów, a zachowywane N najlepszych. Daje to równomierniejszy start, statystycznie bliższy optimum [4].

(b) Mutacja sterowana różnorodnością roju. W każdej iteracji mierzona jest różnorodność jako średnia odległość osobników od centroidu $\bar{x}$:

$$D_t = \frac{1}{N} \sum_{i=1}^N \|x_i - \bar{x}\|. \quad (5)$$

Gdy $D_t < \theta D_0$ (gdzie D_0 – różnorodność początkowa) lub najlepsze rozwiązanie stagnuje, m najgorszych osobników jest perturbowanych jednym z operatorów o ciężkich ogonach:

$$\text{lot Lévy'ego: } x_i \leftarrow g^* + \alpha (ub - lb) \text{Levy}(\beta) \odot (x_i - g^*), \quad (6)$$

$$\text{skok Cauchy'ego: } x_i \leftarrow g^* + \gamma (ub - lb) \text{Cauchy}(0, 1), \quad (7)$$

gdzie krok Lévy'ego wyznaczany jest metodą Mantegny. Re-iniekcja przywraca różnorodność roju, perturbując wyłącznie najgorszych osobników (najlepsze pozostają nienaruszone). Wszystkie dodatkowe ewaluacje (OBL, re-iniekcja) wliczane są do wspólnego budżetu, więc porównanie z SABOA pozostaje uczciwe.

3 Eksperymenty i wyniki

3.1 Konfiguracja badań

Tabela 1: Parametry eksperymentu.

Parametr	Wartość
Zestaw funkcji	CEC2017 (12 funkcji)
Wymiar D	10
Zakres poszukiwań	$[-100, 100]^D$
Liczność populacji N	30
Budżet ewaluacji (MAX_FES)	$10000 \cdot D = 100\,000$
Liczba przebiegów	51
Prawd. przełączania p	0,8
Próg różnorodności θ	0,10
Fracja perturbowanych	0,20 N
Lot Lévy’ego β ; α	1,5; 0,01
Skok Cauchy’ego γ	0,10

Funkcje dobrano tak, aby pokryć wszystkie kategorie CEC2017: **unimodalną** (F1), **multimodalne** (F4, F5, F9), **hybrydowe** (F10, F14, F17) oraz **złożone** (F20, F21, F24, F27, F29). Miarą jakości jest błąd $f(x) - f^*$, gdzie f^* – znane optimum globalne (im niżej, tym lepiej; ideał = 0). Liczba iteracji wynika z budżetu ewaluacji, dzięki czemu oba algorytmy zużywają tyle samo wywołań funkcji celu, a porównanie dotyczy wyłącznie jakości eksploracji.

3.2 Wyniki liczbowe


Tabela 2 zestawia uśrednione wartości błędu. DESABOA uzyskuje niższy błąd średni na *każdej* z 12 funkcji, najczęściej o 1–4 rzędy wielkości.

Tabela 2: Uśrednione wartości błędu $f(x) - f^*$ po 51 przebiegach ($D=10$). Niżej = lepiej; wynik lepszy pogrubiono.


Funkcja	Kategoria	SABOA (śr. $\pm$ odch.)	DESABOA (śr. $\pm$ odch.)
F1	unimodalna	$1.88 \cdot 10^{10} \pm 6.43 \cdot 10^9$	$4.86 \cdot 10^7 \pm 2.49 \cdot 10^7$
F4	multimodalna	$1.99 \cdot 10^4 \pm 2.88 \cdot 10^3$	$1.33 \cdot 10^2 \pm 3.29 \cdot 10^1$
F5	multimodalna	$1.80 \cdot 10^{-2} \pm 1.18 \cdot 10^{-2}$	$8.08 \cdot 10^{-5} \pm 1.51 \cdot 10^{-4}$
F9	multimodalna	$2.17 \cdot 10^3 \pm 2.76 \cdot 10^2$	$8.64 \cdot 10^2 \pm 2.84 \cdot 10^2$
F10	hybrydowa	$1.50 \cdot 10^8 \pm 1.71 \cdot 10^8$	$1.99 \cdot 10^4 \pm 1.11 \cdot 10^4$
F14	hybrydowa	$6.80 \cdot 10^7 \pm 8.96 \cdot 10^7$	$2.51 \cdot 10^5 \pm 2.59 \cdot 10^5$
F17	hybrydowa	$1.31 \cdot 10^8 \pm 2.25 \cdot 10^8$	$4.80 \cdot 10^4 \pm 2.46 \cdot 10^4$
F20	złożona	$1.02 \cdot 10^4 \pm 5.82 \cdot 10^3$	$2.30 \cdot 10^2 \pm 7.31 \cdot 10^1$
F21	złożona	$2.83 \cdot 10^2 \pm 1.77 \cdot 10^2$	$1.14 \cdot 10^2 \pm 1.91$
F24	złożona	$1.43 \cdot 10^3 \pm 3.22 \cdot 10^2$	$5.05 \cdot 10^2 \pm 2.47 \cdot 10^1$
F27	złożona	$9.30 \cdot 10^2 \pm 3.84 \cdot 10^2$	$1.63 \cdot 10^2 \pm 1.08 \cdot 10^2$
F29	złożona	$4.11 \cdot 10^9 \pm 5.12 \cdot 10^9$	$4.07 \cdot 10^6 \pm 6.28 \cdot 10^6$

3.3 Krzywe zbieżności


Rysunki 1–6 przedstawiają średni błąd (skala logarytmiczna) w funkcji liczby ewaluacji. SABOA bardzo szybko stagnuje, podczas gdy DESABOA konsekwentnie obniża błąd dzięki wstrzykiwaniu różnorodności.




Rysunek 1: Krzywe zbieżności – CEC2017 F1 oraz F4 (D=10).




Rysunek 2: Krzywe zbieżności – CEC2017 F5 oraz F9 (D=10).




Rysunek 3: Krzywe zbieżności – CEC2017 F10 oraz F14 (D=10).



Rysunek 4: Krzywe zbieżności – CEC2017 F17 oraz F20 (D=10).




Rysunek 5: Krzywe zbieżności – CEC2017 F21 oraz F24 (D=10).



Rysunek 6: Krzywe zbieżności – CEC2017 F27 oraz F29 (D=10).

3.4 Rozkłady błędu końcowego

Rysunek 7 przedstawia rozrzut błędu końcowego (51 przebiegów) dla po jednej reprezentatywnej funkcji z każdej kategorii.



Rysunek 7: Rozkłady błędu końcowego: F1 (unimodalna), F10 (hybrydowa), F21 i F29 (złożone).

3.5 Test skuteczności (Wilcoxon)

Wyższość DESABOA zweryfikowano sparowanym testem sumy rang Wilcoxon (dwustronnym, $\alpha = 0,05$) na 51 sparowanych przebiegach każdej funkcji (tabela 3). Na wszystkich 12 funkcjach różnica jest istotna statystycznie ($p \approx 5 \cdot 10^{-10} \ll 0,05$), a zwycięzcą zawsze jest DESABOA, co daje bilans **12 zwycięstw / 0 remisów / 0 porażek**.

Tabela 3: Test sumy rang Wilcoxon (sparowany, dwustronny, $\alpha = 0,05$) dla DESABOA względem SABOA. Zwycięzca wg mediany przy $p < 0,05$.

Funkcja	med. SABOA	med. DESABOA	p	Zwycięzca
F1	$1.74 \cdot 10^{10}$	$4.61 \cdot 10^7$	$5.15 \cdot 10^{-10}$	DESABOA
F4	$2.15 \cdot 10^4$	$1.25 \cdot 10^2$	$5.15 \cdot 10^{-10}$	DESABOA
F5	$1.45 \cdot 10^{-2}$	$2.32 \cdot 10^{-5}$	$5.15 \cdot 10^{-10}$	DESABOA
F9	$2.11 \cdot 10^3$	$8.51 \cdot 10^2$	$5.15 \cdot 10^{-10}$	DESABOA
F10	$5.72 \cdot 10^7$	$1.70 \cdot 10^4$	$5.15 \cdot 10^{-10}$	DESABOA
F14	$2.14 \cdot 10^7$	$1.33 \cdot 10^5$	$5.46 \cdot 10^{-10}$	DESABOA
F17	$3.29 \cdot 10^7$	$4.39 \cdot 10^4$	$5.46 \cdot 10^{-10}$	DESABOA
F20	$9.38 \cdot 10^3$	$2.12 \cdot 10^2$	$5.15 \cdot 10^{-10}$	DESABOA
F21	$2.23 \cdot 10^2$	$1.13 \cdot 10^2$	$5.15 \cdot 10^{-10}$	DESABOA
F24	$1.39 \cdot 10^3$	$4.95 \cdot 10^2$	$5.15 \cdot 10^{-10}$	DESABOA
F27	$8.47 \cdot 10^2$	$1.28 \cdot 10^2$	$5.15 \cdot 10^{-10}$	DESABOA
F29	$2.02 \cdot 10^9$	$1.69 \cdot 10^6$	$5.15 \cdot 10^{-10}$	DESABOA

4 Wnioski

- Zaproponowana modyfikacja DESABOA – uczenie przez przeciwności oraz mutacja sterowana różnorodnością roju – istotnie poprawia skuteczność SABOA na całym badanym zestawie CEC2017.
- DESABOA wygrywa **12/12** funkcji zarówno pod względem błędu średniego, jak i istotności statystycznej (test Wilcoxona, $p \approx 5 \cdot 10^{-10}$).
- Największe zyski (do 4 rzędów wielkości) występują na funkcjach hybrydowych i złożonych, gdzie bazowy SABOA najszybciej traci różnorodność i przedwcześnie zbiega – co potwierdza, że niedobór różnorodności był głównym ograniczeniem metody bazowej.
- Ponieważ budżet ewaluacji jest identyczny dla obu algorytmów, poprawa wynika z lepszej eksploracji przestrzeni, a nie z większej liczby ewaluacji.

Literatura

- [1] Sankalap Arora and Satvir Singh. Butterfly optimization algorithm: a novel approach for global optimization. *Soft Computing*, 23(3):715–734, 2019.
- [2] N. H. Awad, M. Z. Ali, J. J. Liang, B. Y. Qu, and P. N. Suganthan. Problem definitions and evaluation criteria for the cec 2017 special session and competition on single objective real-parameter numerical optimization. Technical report, Nanyang Technological University, Singapore, 2016.
- [3] Yuqi Fan, Junpeng Shao, Guitao Sun, and Xuan Shao. A self-adaption butterfly optimization algorithm for numerical optimization problems. *IEEE Access*, 8:88026–88041, 2020.
- [4] Yue-Jiao Gong, Jing-Jing Li, Yicong Zhou, Yun Li, Henry Shu-Hung Chung, Yu-Hui Shi, and Jun Zhang. Genetic learning particle swarm optimization. *IEEE Transactions on Cybernetics*, 46(10):2277–2290, 2016.